

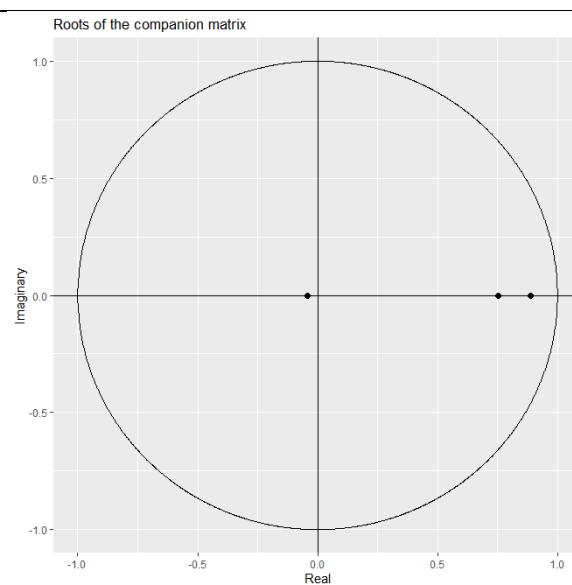
1. Evaluasi dan Proyeksi PDRB Kabupaten Nganjuk

Pada laporan interim, peneliti melakukan proyeksi dengan menggunakan model Panel Vector Autoregressive berdasarkan fixed effect OLS dan two-steps GMM.

1.1. *Panel VAR Fixed Effect OLS (Demeaning)*

Peneliti menggunakan data panel PDRB total; lapangan usaha industri pengolahan; lapangan usaha pertanian, kehutanan, dan perikanan dalam menyusun model proyeksi Panel VAR. Data panel tersebut terdiri dari 418 observasi dari seluruh kab/kota di Jawa Timur, dari tahun 2010 sampai dengan tahun 2020. Data tahun 2021 dan 2022 digunakan untuk melakukan evaluasi hasil proyeksi pada tahun 2021 dan 2022.

Tabel 2.1. Uji Stabilitas Panel VAR Fixed Effect.

Tabel Uji Stabilitas			Gambar Uji Stabilitas
Eigenvalue	Modulus		
0.888129	0.888129		
0.75415	0.75415		
-0.04178	0.04178		

Sumber: Peneliti, diolah.

Tabel 2.1. menampilkan hasil uji stabilitas model panel VAR Fixed effect. Kami menggunakan eigenvalue dan modulus dalam menganalisis stabilitas dari model. Eigenvalue, yang dalam bahasa Indonesia bisa disebut sebagai nilai eigen atau akar karakteristik, adalah konsep penting dalam matematika khususnya linear algebra. Eigenvalue terkait erat dengan konsep lain yaitu eigenvector (vektor eigen). Secara intuitif, bayangkan sebuah transformasi linear yang bisa mempengaruhi arah dan panjang dari vektor. Eigenvector adalah vektor spesial yang arahnya tidak diubah oleh transformasi tersebut, meskipun panjangnya bisa saja berubah. Besar perubahan panjang inilah yang diwakili oleh eigenvalue. Eigenvalue positif berarti panjang vektor akan bertambah, negatif berarti dipendekkan, dan nol berarti tidak

berubah panjangnya. Gambar di tabel 2.1. menunjukkan bahwa nilai eigen berada di dalam unit lingkaran, menunjukkan bahwa model memiliki stabilitas yang baik.

Tabel 2.2. Regresi Panel VAR Fixed Effect OLS (Demeaning).

	demeaned_log_pdrb_total	demeaned_log_industri_pengolahan	demeaned_log_pertanian
demeaned_lag1_log_pdrb_total	0.8665 ***	0.7551 ***	0.0205
Standard Errors	-0.0234	-0.1436	-0.0154
demeaned_lag1_log_industri_pengolahan	-0.003	-0.0429	0.0017
Standard Errors	-0.0078	-0.0477	-0.0051
demeaned_lag1_log_pertanian	0.1235 **	0.7282 *	0.7770 ***
Standard Errors	-0.0473	-0.2894	-0.031

Sumber: Peneliti, diolah. *** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$.

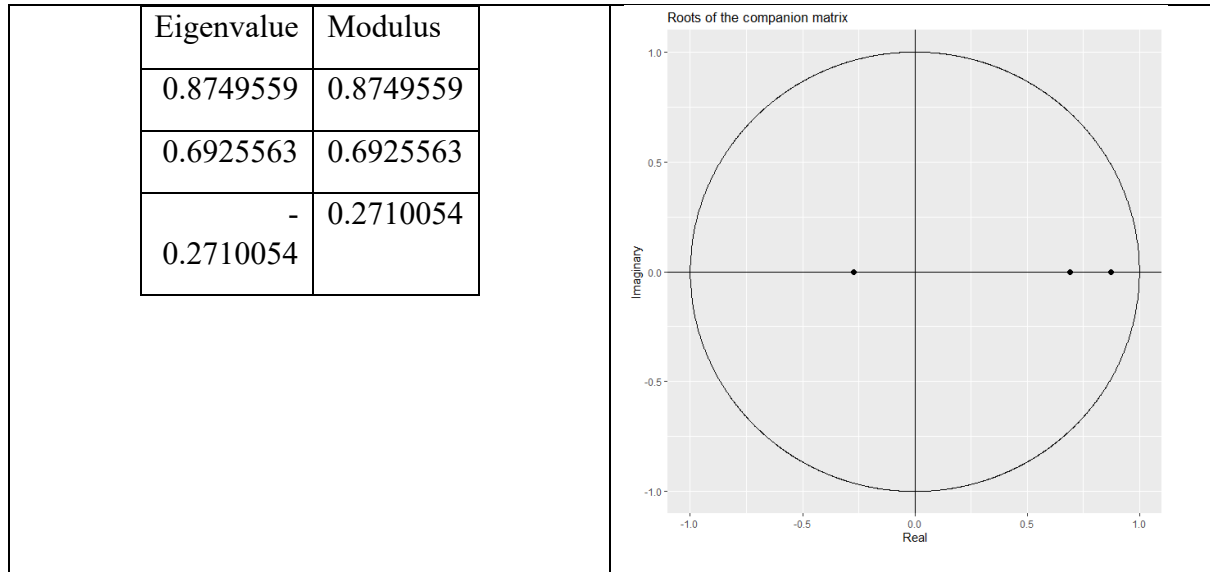
Tabel 2.2 menampilkan hasil regresi model panel VAR dengan menggunakan fixed effects OLS. Seluruh variable diubah dengan menggunakan transformasi demeaning, dengan menggunakan lag 1 sebagai variable dinamis di dalam model. Tabel ini menunjukkan bahwa PDRB total di provinsi jawa timur berkorelasi kuat dengan nilai masa lalunya (1 tahun lalu), dan nilai masa lalu dari lapangan usaha pertanian, kehutanan, dan perikanan. Lapangan usaha industri pengolahan berkorelasi kuat dengan nilai masa lalu PDRB total dan lapangan usaha pertanian, kehutanan, dan perikanan. Di sisi lain, lapangan usaha pertanian, kehutanan, dan perikanan berkorelasi kuat dengan nilai masa lalunya, tidak dengan nilai masa lalu variable lain.

1.2.Panel VAR Generalized Method of Moment (GMM) two-steps and forward Orthogonal

Dengan menggunakan data panel yang sama, peneliti menggunakan model panel yang lain yaitu two-steps GMM. Fitur utama dari two-steps GMM adalah penggunaan variable instrument sebagai instrument variable endogen. Variabel instrument terdiri dari nilai masa lalu variable endogen.

Tabel 2.3. Uji Stabilitas Panel VAR two-steps GMM.

Tabel Uji Stabilitas	Gambar Uji Stabilitas
----------------------	-----------------------



Sumber: Peneliti, diolah.

Dengan menggunakan nilai eigen dan modulus, tabel 2.3 menunjukkan bahwa two-steps GMM panel VAR dalam kondisi yang stabil. Kondisi stabil tersebut ditunjukkan oleh nilai eigen yang berada di dalam unit lingkaran. Selain menguji stabilitas model, peneliti melakukan pemilihan model dengan menggunakan Andrew & Lu (2001) selection procedure.

1.2.1. Andrews–Lu model selection procedure

Peneliti mengikuti Andrews & Lu (2001) dalam pemilihan model berdasarkan kriteria seleksi momen (MMSC). Persamaan dasar MMSC sebagai berikut.

$$MMSC_n(b, c) = J_n(b, c) - h(|c| - |b|)\kappa_n \quad (2.1)$$

$J_n(b, c)$ adalah Hansen overidentification test, b menunjukkan jumlah parameter, c menunjukkan jumlah kondisi momen, dan n menunjukkan total observasi. Tabel di bawah menggunakan spesifikasi persamaan yang sedikit berbeda dari persamaan dasar MMSC, yaitu:

$$MMSC_n(b, c) = J_n(b, c) - h(|c| - |b|)\kappa_n \quad (2.2)$$

$$MMSC_{BIC,n}(b, c) = J_n(b, c) - h(|c| - |b|) \cdot \ln(n) \quad (2.3)$$

$$MSC_{AIC,n}(b, c) = J_n(b, c) - h(|c| - |b|) \cdot 2 \quad (2.4)$$

$$MSC_{HQIC,n}(b, c) = J_n(b, c) - Q \cdot h(|c| - |b|) \cdot \ln(\ln(n)) \quad (2.5)$$

Andrews & Lu (2001) merekomendasikan MMSC-BIC (Bayesian information criterion) atau MMSC-HQIC (Hannan-Quinn information criterion). MMSC-AIC (Akaike information criterion) tidak memenuhi kriteria konsistensi karena kriteria ini memiliki probabilitas positif meskipun ketika peneliti memilih terlalu sedikit over-identifying restrictions.

Tabel 2.4. Andrews-Lu model selection procedure

Indikator	Lag 1	Lag 2
BIC	-155.9834	-63.95463
AIC	-29.43466	47.5562
HQIC	-85.6689	-2.281087

Sumber: Peneliti, diolah.

Tabel 2.4 menunjukkan bahwa nilai BIC dan HQIC memiliki nilai terkecil ketika peneliti menggunakan lag 1, dibandingkan lag 2. Jumlah lag (nilai masa lalu) variable endogen yang dimasukkan ke dalam model, mempengaruhi nilai BIC dan HQIC.

Tabel 2.5. Regresi Panel VAR GMM two-steps and forward orthogonal.

	log_pdrb_total	log_industri_pengolahan	log_pertanian
lag1_log_pdrb_total	0.7946***	0.716***	-0.0445
Standard Errors	-0.0355	-0.1242	-0.0423
lag1_log_industri_pengolahan	-0.0009	0.0051	0.0098
Standard Errors	-0.0072	-0.0498	-0.0106
lag1_log_pertanian	0.2356**	0.5894**	0.8692***
Standard Errors	-0.0784	-0.2046	-0.0779

Sumber: Peneliti, diolah. *** $p < 0.001$; ** $p < 0.01$; * $p < 0.05$.

Tabel 2.5 menampilkan hasil regresi two-steps GMM panel VAR, yang menunjukkan hasil yang konsisten dengan hasil regresi panel fixed effect. Temuan konsisten ini menunjukkan bahwa PDRB total di provinsi jawa timur berkorelasi kuat dengan nilai masa lalunya (1 tahun lalu), dan nilai masa lalu dari lapangan usaha pertanian, kehutanan, dan perikanan. Lapangan usaha industri pengolahan berkorelasi kuat dengan nilai masa lalu PDRB total dan lapangan usaha pertanian, kehutanan, dan perikanan. Di sisi lain, lapangan usaha pertanian, kehutanan, dan perikanan berkorelasi kuat dengan nilai masa lalunya, tidak dengan nilai masa lalu variable lain.

1.3 Hasil Evaluasi Proyeksi *Panel VAR*

Tabel 2.6 menampilkan hasil evaluasi in-sample proyeksi PDRB total; lapangan usaha industri pengolahan; lapangan usaha pertanian, kehutanan, dan perikanan. Pada hasil proyeksi PDRB total, nilai yang dilaporkan menunjukkan kesalahan dalam persentase. Nilai negatif

menunjukkan model *underestimates* PDRB aktual, sedangkan nilai positif menunjukkan perkiraan yang terlalu tinggi. Kesalahan berkisar antara -3.95% hingga 2.04%, menandakan bahwa prediksi model cukup dekat dengan nilai PDRB aktual di sebagian besar tahun. Idealnya, persentase kesalahan yang lebih rendah menunjukkan prakiraan yang lebih akurat. Dalam hal ini, sebagian besar kesalahan berada di bawah 1% secara absolut, menunjukkan kecocokan yang baik antara prediksi model dan PDRB aktual. Terdapat beberapa pengecualian, seperti tahun 2018 (3.948%) dan 2019 (-2.215%), di mana prakiraan model menyimpang lebih signifikan dari PDRB aktual.

Model PVAR telah menangkap tren PDRB regional di Nganjuk dengan cukup baik untuk sebagian besar periode (2011-2020). Kesalahan yang relatif rendah menunjukkan bahwa prakiraan model umumnya dekat dengan nilai PDRB aktual. Namun, kesalahan yang terkadang lebih besar menyoroti keterbatasan model dalam memprediksi fluktuasi ekonomi secara sempurna.

Tabel 2.6. Hasil Evaluasi In-Sample Proyeksi Panel VAR.

Tahun	Percentage Error PDRB total (%)	Percentage Error Industri Pengolahan (%)	Percetage Error Pertanian, Kehutanan, dan Perikanan (%)
2011	-1.596	-0.410	-0.269
2012	-1.233	-2.967	0.578
2013	-1.499	-4.620	-1.805
2014	-0.471	-2.662	-0.210
2015	0.165	-2.160	1.178
2016	0.402	-3.113	1.526
2017	0.614	-2.537	-0.453
2018	2.042	4.010	-1.626
2019	3.948	10.975	0.601
2020	-2.215	4.521	0.535

Sumber: Peneliti, diolah.

Pada hasil evaluasi proyeksi lapangan usaha industri pengolahan, kesalahan berkisar antara -10,98% hingga 4,01%, menandakan bahwa prediksi model menyimpang dari nilai aktual dalam derajat yang bervariasi. Idealnya, persentase kesalahan yang lebih rendah

menunjukkan prakiraan yang lebih akurat. Dalam hal ini, beberapa kesalahan berada di bawah 3% (secara absolut), yang mungkin dapat diterima tergantung pada standar keakuratan khusus untuk industri tersebut. Namun, ada juga kesalahan yang signifikan, terutama dari tahun 2017 dan seterusnya (4,01% hingga 10,98%). Ini menunjukkan bahwa model mengalami kesulitan untuk memprediksi secara tepat pertumbuhan/penurunan industri pengolahan pada tahun-tahun tersebut.

Industri pengolahan mungkin lebih rentan terhadap fluktuasi yang tidak terduga dibandingkan dengan sektor lain seperti pertanian. Model mungkin tidak menangkap fluktuasi ini secara efektif. Asumsi model PVAR tentang faktor-faktor yang mempengaruhi industri pengolahan mungkin tidak sepenuhnya akurat dalam kasus ini. Model ini bekerja lebih baik di beberapa tahun (kesalahan lebih dekat ke 0%) tetapi menunjukkan keterbatasan dalam menangkap fluktuasi signifikan, terutama di tahun-tahun belakangan (2017-2020).

Pada hasil evaluasi proyeksi lapangan usaha pertanian, kehutanan, dan perikanan, kesalahan berkisar antara -1,81% hingga 1,53%, menandakan bahwa prediksi model secara umum dekat dengan nilai aktual di sebagian besar tahun. Idealnya, persentase kesalahan yang lebih rendah menunjukkan prakiraan yang lebih akurat. Dalam hal ini, sebagian besar kesalahan berada di bawah 2% (secara absolut), menunjukkan kecocokan yang baik antara prediksi model dan kinerja sektor ini secara aktual. Model PVAR telah menangkap tren sektor pertanian di Nganjuk dengan cukup baik untuk sebagian besar periode (2011-2020). Kesalahan yang relatif rendah menunjukkan bahwa prakiraan model umumnya dekat dengan nilai aktual.

Tabel 2.7 menampilkan hasil evaluasi out-sample dengan menggunakan model proyeksi Panel VAR. Pada hasil PDRB total, nilai yang dilaporkan menunjukkan kesalahan dalam persentase. Nilai negatif menunjukkan model *underestimates* tingkat PDRB aktual, sedangkan nilai positif menunjukkan perkiraan yang terlalu tinggi. Pada tahun 2021, prediksi model over-estimasi tingkat PDRB aktual sebesar 1.33%. Ini menunjukkan kinerja ekonomi aktual sedikit lebih rendah dari yang diantisipasi model. Pada tahun 2022, prediksi model cukup dekat dengan pertumbuhan PDRB aktual, dengan sedikit under-estimasi sebesar 0.37%. Prediksi model PVAR terlihat masuk akal untuk tingkat PDRB Nganjuk pada tahun 2021 dan 2022, dengan sedikit over-estimasi pada tahun 2021 dan sedikit under-estimasi pada tahun 2022.

Penting untuk diingat bahwa ini adalah kesalahan out-of-sample. Berbeda dengan kesalahan in-sample yang menilai kecocokan model pada data historis, kesalahan out-of-sample mengevaluasi keakuratannya dalam memprediksi tren masa depan. Prakiraan model

PVAR, terutama untuk periode out-of-sample, memiliki ketidakpastian bawaan dari model. Kejadian yang tidak terduga dapat menyebabkan deviasi antara prediksi dan nilai aktual.

Tabel 2.7. Hasil Evaluasi Out-Sample Proyeksi Panel VAR.

Tahun	Percentage Error PDRB total (%)	Percentage Error Industri Pengolahan (%)	Percetage Error Pertanian, Kehutanan, dan Perikanan (%)
2021	1.346	-4.935	0.538
2022	-0.372	-13.904	0.679

Sumber: Peneliti, diolah.

Kesalahan hasil proyeksi industri pengolahan adalah 4.94% untuk tahun 2021 dan 13.90% untuk tahun 2022. Karena keduanya bernilai negatif, model memprediksi nilai sektor ini kurang dari nilai aktual industri pengolahan di kedua tahun tersebut.

Pada tahun 2021, prediksi model under-estimasi tingkat aktual industri pengolahan sebesar 4.94%. Ini menunjukkan bahwa kinerja sektor tersebut lebih baik dari yang diantisipasi oleh model. Pada tahun 2022, kekurangan estimasi model jauh lebih besar, yaitu 13.90%. Ini menunjukkan perbedaan signifikan antara tingkat pertumbuhan yang diprediksi dan aktual. Industri pengolahan rentan terhadap fluktuasi yang tidak terduga karena berbagai faktor. Model mungkin tidak menangkapnya secara efektif dalam prediksi out-of-sample. Kejadian yang tidak terduga atau perubahan dalam lanskap ekonomi dapat memengaruhi pertumbuhan industri secara berbeda dari yang diantisipasi model.

Kesalahan proyeksi lapangan usaha pertanian, kehutanan, dan perikanan adalah 0,54% untuk tahun 2021 dan 0.68% untuk tahun 2022. Pada tahun 2021, prediksi model over-estimasi tingkat aktual output pertanian sebesar 0.54%. Pada tahun 2022, over-estimasi model sedikit lebih besar, yaitu 0.68%. Pada dasarnya, model memprediksi tingkat output pertanian yang sedikit lebih tinggi untuk kedua tahun tersebut dibandingkan dengan yang sebenarnya terjadi. Kesalahan yang kecil, kurang dari 1%, menunjukkan bahwa kemampuan model Panel VAR dalam memprediksi nilai lapangan usaha ini sudah baik.

1.4 Bayesian Global VAR

Peneliti menggunakan data panel PDRB total; lapangan usaha industri pengolahan; lapangan usaha pertanian, kehutanan, dan perikanan dalam menyusun model proyeksi bayesian Global VAR. Data panel tersebut terdiri dari 418 observasi dari seluruh kab/kota di Jawa Timur, dari

tahun 2010 sampai dengan tahun 2020. Data tahun 2021 dan 2022 digunakan untuk melakukan evaluasi hasil proyeksi pada tahun 2021 dan 2022. Peneliti menggunakan lag 1 tahun.

Model kami menghasilkan 192 (4%) *draws* (*active trimming*). Dengan kata lain, model yang kami jalankan menghasilkan 192 set perkiraan (mempertimbangkan ketidakpastian dalam parameter dasar) setelah membuang sebagian kecil awal (4%) yang mungkin tidak representatif. 192 *draws* mewakili jumlah sampel yang dihasilkan model dari distribusi posterior. Secara lebih sederhana, model menjalankan simulasi sebanyak 192 kali untuk memperhitungkan ketidakpastian dalam parameter yang diperkirakan. Persentase (4%) menunjukkan bahwa 4% dari penarikan awal dibuang selama "*active trimming*". Ini adalah praktik umum dalam estimasi Bayesian untuk menghapus sampel awal yang mungkin tidak secara akurat mencerminkan distribusi posterior. *Active trimming* mengacu pada teknik khusus yang digunakan untuk menghilangkan sampel awal yang berpotensi tidak dapat diandalkan. Ini adalah cara untuk meningkatkan efisiensi model dengan berfokus pada bagian yang lebih relevan dari distribusi posterior.

Model kami memiliki variabel eksogen lemah dengan lag adalah 1. Variabel ini dimasukkan ke dalam model tetapi tidak sepenuhnya dijelaskan oleh variabel endogen lain dalam sistem. Variabel ini mungkin sedikit memengaruhi variabel endogen, tetapi perilaku mereka sendiri ditentukan oleh faktor eksternal. Lag sama dengan 1 menunjukkan bahwa model BGVAR mempertimbangkan dampak variabel eksogen lemah pada variabel endogen dengan penundaan satu periode/satu tahun. Dengan kata lain, model mengasumsikan bahwa nilai saat ini dari variabel eksogen lemah memengaruhi variabel endogen di periode berikutnya, tetapi tidak harus pada periode yang sedang berjalan.

Kami menggunakan Markov Chain Monte Carlo (MCMC) simulations untuk mengestimasi parameter di dalam model kami. Kami menggunakan status konvergensi dengan menggunakan Geweke statistics. Diagnostik konvergensi membantu menilai seberapa baik simulasi MCMC telah mencapai keadaan stabil, di mana sampel mewakili distribusi posterior aktual dari parameter. Geweke statistics adalah alat diagnostik umum yang digunakan untuk membandingkan mean dari bagian awal dan akhir rantai simulasi MCMC. Aturan praktis menunjukkan bahwa jika statistik Geweke (nilai-z) berada dalam kisaran tertentu (umumnya $\pm 1,96$) untuk sebagian besar variabel, ini menunjukkan konvergensi yang baik.

Hasil diagnostik model kami menunjukkan bahwa terdapat proporsi sebesar 28.79% dari variabel dalam model kami, yang memiliki nilai statistik Geweke berada di luar kisaran

$\pm 1,96$. Ini menunjukkan potensi masalah konvergensi. Terdapat beberapa alasan terkait belum tercapainya konvergensi.

- Iterasi MCMC Tidak Cukup: Simulasi mungkin belum berjalan cukup lama untuk mencapai keadaan stabil.
- Kompleksitas Model: Model kompleks dengan banyak parameter lebih sulit untuk simulasi MCMC agar konvergen secara efektif.

Peneliti juga menggunakan uji statistik (F-statistik) untuk menilai hipotesis nol tentang tidak adanya autokorelasi serial dalam residual model. Autokorelasi serial berarti bahwa kesalahan (residual) dari satu periode berkorelasi dengan kesalahan pada periode selanjutnya. Dengan kata lain, kesalahan masa lalu memengaruhi kesalahan masa kini. Proporsi Tinggi nilai- $p > 0.1$ (86.84%) menunjukkan bahwa untuk sebagian besar unit (kota/kabupaten), uji-F tidak menolak hipotesis nol pada tingkat signifikansi 10%. Ini menunjukkan bukti lemah adanya autokorelasi serial orde satu dalam residual antar unit untuk sebagian besar unit. Persentase sisanya (sekitar 13%) termasuk dalam kategori dengan nilai- p yang lebih rendah, menunjukkan kemungkinan adanya autokorelasi serial pada sejumlah kecil unit. Namun, jumlah spesifik unit dengan masalah ini tergantung pada tingkat signifikansi yang dipilih (misalnya, 5% atau 1%).

Hasil uji-F menunjukkan bahwa, di sebagian besar unit model BGVAR, kemungkinan tidak ada autokorelasi serial orde satu yang signifikan dalam residual antar unit. Ini adalah tanda baik, yang menunjukkan bahwa residual model tidak berkorelasi secara sistematis melintasi periode waktu untuk sebagian besar unit. Secara lengkap, hasil uji F ditunjukkan oleh tabel 2.8.

Tabel 2.8. F-test, first order serial autocorrelation of cross-unit residuals.

\	p-value	In %
>0.1	99	86.64
0.05-0.1	10	8.77
0.01-0.05	5	4.39
<0.01	0	0

Sumber: Peneliti, diolah.

Peneliti juga melihat korelasi silang antar unit rata-rata dari residual unit-model dalam model BGVAR. Korelasi antar unit mengacu pada korelasi antara residual dari unit yang berbeda dalam model kami. Unit mewakili wilayah (kota/kabupaten) dalam studi ini. Residual unit-model adalah istilah kesalahan untuk setiap unit setelah mempertimbangkan pengaruh variabel lain dalam model. Mereka mewakili bagian data regional yang tidak dapat dijelaskan.

Tabel 2.9 merangkum korelasi rata-rata antara residual dari setiap pasangan unit, dikategorikan menurut nilai absolut dari koefisien korelasi. Koefisien korelasi berkisar dari -1 (korelasi negatif sempurna) hingga +1 (korelasi positif sempurna), dengan 0 menunjukkan tidak ada korelasi. Sebagian besar pasangan unit menunjukkan korelasi di bawah 0.2 (60.54% hingga 84.21%), menunjukkan hubungan linear yang lemah hingga moderat antara residual mereka. Ini adalah tanda yang baik, yang menunjukkan bahwa residual sebagian besar wilayah tidak saling mempengaruhi secara kuat. Sebagian besar pasangan unit (sekitar 36.84% hingga 52.63%) menunjukkan korelasi antara 0.2 dan 0.5, menunjukkan hubungan linear yang sedikit lebih kuat (positif atau negatif) antara residual mereka. Penting untuk menyelidiki pasangan ini lebih lanjut untuk memahami alasan mendasar dari hubungan ini. Tidak ada pasangan unit dengan korelasi melebihi 0.5, menunjukkan tidak adanya hubungan linear yang sangat kuat antara residual kota/kabupaten mana pun.

Tabel 2.9. Average pairwise cross-unit correlation of unit-model residuals.

\	PDRB total	Industri Pengolahan	Pertanian, Kehutanan, dan Perikanan
<0.1	7 (18.42%)	9 (23.68%)	17 (44.74%)
0.1-0.2	16 (42.11%)	9 (23.68%)	14 (36.84%)
0.2-0.5	15 (39.47%)	20 (52.63%)	7 (18.42%)
>0.5	0	0	0

Sumber: Peneliti, diolah.

Secara umum, hasil pada tabel 2.9 menunjukkan bahwa residual model BGVAR memperlihatkan korelasi tingkat lemah hingga moderat di sebagian besar pasangan kota/kabupaten. Ini menunjukkan bahwa model secara efektif menangkap kekhasan

kota/kabupaten dan kesalahan yang tidak dapat dijelaskan tidak saling mempengaruhi secara berlebihan.

1.5 Hasil Evaluasi Proyeksi *Bayesian Global VAR*.

Tabel 2.10 menampilkan hasil evaluasi in-sample proyeksi PDRB total; lapangan usaha industri pengolahan; lapangan usaha pertanian, kehutanan, dan perikanan dengan pendekatan bayesian Global VAR. Pada hasil proyeksi PDRB total, nilai yang dilaporkan menunjukkan kesalahan dalam persentase. Nilai negatif menunjukkan model *underestimates* PDRB aktual, sedangkan nilai positif menunjukkan perkiraan yang terlalu tinggi. Secara umum, nilai absolut kesalahan yang semakin kecil menunjukkan keakuratan perkiraan model yang semakin baik. Dalam hal ini, sebagian besar kesalahan berada di bawah 0.1%, yang menunjukkan kinerja yang baik dari model BGVAR dalam memperkirakan PDRB regional di Nganjuk.

Tabel 2.10. Hasil Evaluasi In-Sample Proyeksi Bayesian Global VAR.

Tahun	Percentage Error PDRB total (%)	Percentage Error Industri Pengolahan (%)	Percetage Error Pertanian, Kehutanan, dan Perikanan (%)
2011	0.037	-0.312	-0.025
2012	-0.077	0.023	-0.373
2013	0.003	0.306	0.453
2014	0.008	0.234	0.233
2015	-0.002	0.013	0.091
2016	0.011	-0.057	-0.230
2017	0.008	0.083	-0.145
2018	-0.020	-0.654	0.389
2019	0.002	0.235	-0.183
2020	-0.001	-0.023	0.017

Sumber: Peneliti, diolah.

Nilai negatif pada kesalahan proyeksi industri pengolahan (seperti -0.312% pada tahun 2011) menunjukkan bahwa model under-estimasi output Industri Pengolahan aktual. Ini berarti model tersebut memprediksi output yang lebih rendah daripada yang terjadi pada kenyataannya. Sebaliknya, nilai positif, seperti 0.235% pada tahun 2019, menunjukkan bahwa

model tersebut over-estimasi output Industri Pengolahan aktual. Artinya, model memprediksi output yang lebih tinggi daripada yang terjadi pada kenyataannya.

Meskipun ada campuran nilai positif dan negatif, perlu diperhatikan besarnya kesalahan secara absolut. Idealnya, kesalahan yang lebih kecil menunjukkan keakuratan perkiraan yang lebih baik. Evaluasi in-sample menunjukkan bahwa model BGVAR memiliki tingkat akurasi yang lebih baik dalam memperkirakan output Industri Pengolahan di Nganjuk dari 2011 hingga 2020.

Nilai negatif kesalahan proyeksi lapangan usaha pertanian, kehutanan, dan perikanan, seperti -0.373% pada tahun 2012, menunjukkan bahwa model under-estimasi output sektor pertanian aktual. Ini berarti model memprediksi output yang lebih rendah daripada yang terjadi pada kenyataannya. Nilai positif, seperti 0.453% pada tahun 2013, menunjukkan bahwa model over-estimasi output sektor pertanian aktual. Artinya, model memprediksi output yang lebih tinggi daripada yang terjadi pada kenyataannya. Evaluasi in-sample menunjukkan tingkat akurasi yang lebih baik dalam perkiraan model BGVAR untuk output sektor pertanian di Nganjuk dari 2011 hingga 2020, dibandingkan dengan proyeksi model Panel VAR.

Tabel 2.11. Hasil Evaluasi Out-Sample Proyeksi Bayesian Global VAR.

Tahun	Percentage Error PDRB total (%)	Percentage Error Industri Pengolahan (%)	Percentage Error Pertanian, Kehutanan, dan Perikanan (%)
2021	-1.447	-3.891	-1.348
2022	-4.040	-11.476	-1.089

Sumber: Peneliti, diolah.

Tabel 2.11 menampilkan hasil evaluasi out-sample dengan menggunakan model proyeksi Bayesian Global VAR. Hasil pada tabel menunjukkan keakuratan perkiraan model BGVAR untuk Produk Domestik Bruto Regional (PDRB), output Industri Pengolahan, dan output sektor Pertanian di Nganjuk dari tahun 2021 hingga 2022. Namun, perlu dicatat bahwa ini adalah evaluasi out-of-sample, artinya data dari periode ini tidak digunakan untuk membangun model tetapi untuk menguji kemampuan prediksinya. Tabel tersebut menampilkan persentase kesalahan antara perkiraan model BGVAR dan nilai aktual untuk setiap variabel (PDRB, Industri Pengolahan, Pertanian) pada tahun 2021 dan 2022. Nilai negatif menunjukkan bahwa model under-estimasi nilai aktual, sedangkan nilai positif menunjukkan bahwa model over-estimasi nilai aktual.

1.6 Time Varying Factor Augmented Linear Regression

Peneliti melakukan estimasi time varying factor augmented linear regression dengan mengombinasikan analisis principal component dan time varying kernel regression. Kami menggunakan time series data dengan observasi berjumlah 13 observasi dari 114 variables. 114 variables ini terdiri dari PDRB total, industri pengolahan, dan pertanian untuk setiap kota/kabupaten di Jawa Timur. Saya mengubah data saya dengan melakukan normalisasi berdasarkan mean dan standar deviasi dari data. Kemudian, kami merubah data yang hasil normalisasi dengan menggunakan logaritma natural.

Data dinormalisasi berdasarkan mean dan standar deviasi. Normalisasi bertujuan untuk menstandarisasi data sehingga variabel-variabelnya memiliki skala yang sama. Hal ini penting untuk meningkatkan stabilitas dan akurasi model analisis. Data hasil normalisasi kemudian ditransformasi menggunakan logaritma natural. Transformasi logaritma sering digunakan dalam analisis data time series untuk menangani data yang tidak terdistribusi normal dan/atau untuk mengurangi heteroskedastisitas (varians yang tidak konstan).

Tabel 2.12 Hasil Analisis Principal Component.

\	PC 1	PC 2	PC 3
Standard Deviation	10.35	1.74	1.07
Proportion of Variance	0.94	0.03	0.01
Cumulative Proportion	0.94	0.97	0.98

Sumber: Peneliti, diolah.

Berdasarkan tabel 2.12, analisis PCA berhasil mengekstraksi tiga komponen utama (PC) yang menjelaskan sebagian besar variansi dalam data kami. Komponen utama ini merupakan kombinasi linear dari variabel asli yang menangkap sebagian besar informasi yang terkandung dalam data. Analisis PCA berhasil mereduksi data dari 114 variabel menjadi tiga komponen utama yang masih menjelaskan sebagian besar variansi.

PC1 adalah komponen paling penting karena memiliki standar deviasi tertinggi (10.3539) dan menjelaskan proporsi variansi terbesar (94.04%) dalam data. Ini menunjukkan bahwa PC1 menangkap sebagian besar pola dan tren dalam data kami. PC2 menjelaskan proporsi variansi yang lebih kecil (2.66%), diikuti oleh PC3 (1.00%). Ini menunjukkan bahwa

komponen-komponen ini menangkap tren dan pola yang kurang dominan dalam data. Proporsi Varians Kumulatif menunjukkan bahwa ketiga komponen utama pertama (PC1, PC2, dan PC3) secara bersama-sama menjelaskan 97.70% dari keseluruhan variansi dalam data. Ini berarti sebagian besar informasi yang relevan dalam data kami telah ditangkap oleh tiga komponen utama ini.

Selanjutnya, peneliti menggunakan PC1 sampai PC3 sebagai variabel penjelas untuk melakukan proyeksi PDRB total, industri pengolahan, dan pertanian. Peneliti menggunakan pendekatan time varying kernel regresison dengan spesifikasi tersebut. Peneliti terlebih dahulu menentukan bandwidth number berdasarkan spesifikasi leave-one-out cross-validation, local linier sebagai metode estimasi non-parametric, dan Gaussian kernel function. Leave-one-out cross-validation digunakan untuk memilih bandwidth optimal dengan cara melakukan pelatihan model pada subset data dan mengevaluasi kinerjanya pada data yang tersisa (satu observasi). Proses ini diulangi untuk setiap observasi dalam dataset, dan bandwidth yang menghasilkan kesalahan prediksi rata-rata terendah dipilih sebagai nilai optimal. Estimasi lokal linier digunakan untuk memperkirakan nilai variabel target pada titik baru dengan cara mencocokkan data di sekitarnya. Bandwidth menentukan seberapa jauh data di sekitar titik baru yang akan dipertimbangkan dalam perkiraan. Fungsi Gaussian kernel digunakan untuk menghitung bobot data dalam estimasi lokal linier. Bobot tertinggi diberikan pada data yang paling dekat dengan titik baru, dan bobotnya menurun seiring jaraknya bertambah.

Tabel 2.13. Bandwidth Number.

Min	1st Quartile	Median	Mean	3rd Quartile	Max
0.519	0.519	0.519	0.519	0.519	0.519

Sumber: Peneliti, diolah.

Tabel 2.13 menunjukkan nilai bandwidth minimum, kuartil pertama, median, mean, kuartil ketiga, dan maksimum. Semua nilai statistik deskriptif (minimum, kuartil pertama, median, mean, kuartil ketiga, dan maksimum) sama dengan 0.519. Nilai bandwidth yang sama di semua statistik deskriptif menunjukkan bahwa algoritma cross-validation leave-one-out telah konvergen pada nilai optimal. Nilai bandwidth yang konvergen meningkatkan keamanan model, menunjukkan bahwa model telah memilih bandwidth yang paling sesuai untuk meminimalkan kesalahan prediksi.

Tabel 2.14. Hasil Time Varying Kernel Regression.

\	(Intercept)	PC1_lag	PC2_lag	PC3_lag
Min	-0.751	-2.169	-1.275	-0.556
1st Quartile	-0.613	0.231	-0.534	-0.065
Median	-0.291	0.423	0.122	-0.039
Mean	-0.012	0.522	-0.154	0.099
3rd Quartile	0.663	1.118	0.187	0.131
Max	1.024	2.578	0.8320	1.324
Banwidth = 0.59; Pseudo R2 = 0.958				

Sumber: Peneliti, diolah.

Tabel 2.14 menunjukkan distribusi minimum, kuartil pertama, median, mean, kuartil ketiga, dan nilai maksimum dari koefisien terprediksi untuk setiap variabel independen:

- Intercept: Nilai koefisien berkisar antara -0.75130 hingga 1.02415, menunjukkan pengaruh awal yang bervariasi pada PDRB Nganjuk.
- PC1_lag: Nilai koefisien berkisar antara -2.1685 hingga 2.5775, menunjukkan bahwa PC1_lag memiliki korelasi yang signifikan pada PDRB Nganjuk, dengan efek positif rata-rata (median: 0.4229).
- PC2_lag: Nilai koefisien berkisar antara -1.2745 hingga 0.8320, menunjukkan bahwa PC2_lag memiliki korelasi yang lebih kecil pada PDRB Nganjuk dibandingkan PC1_lag, dengan efek negatif rata-rata (median: -0.1537).
- PC3_lag: Nilai koefisien berkisar antara -0.55558 hingga 1.32360, menunjukkan bahwa PC3_lag memiliki korelasi yang lebih kecil dan bervariasi pada PDRB Nganjuk dibandingkan PC1_lag dan PC2_lag, dengan efek positif rata-rata (median: 0.09929).

Nilai pseudo R-squared adalah 0.9584. Nilai ini menunjukkan bahwa model menjelaskan 95.84% dari variasi dalam logaritma natural PDRB Nganjuk. Ini menunjukkan model yang kuat dengan daya prediksi yang tinggi. Nilai bandwidth optimal adalah 0.519. Bandwidth ini menentukan seberapa "lokal" model dalam mempertimbangkan data saat membuat prediksi. Nilai yang lebih kecil menunjukkan lokalitas yang lebih tinggi, sedangkan nilai yang lebih besar menunjukkan lokalitas yang lebih rendah.

Regresi kernel time-varying berhasil memodelkan hubungan antara PDRB Nganjuk dan komponen utama (PC1_lag, PC2_lag, PC3_lag) dengan mempertimbangkan perubahan efektivitas variabel independen dari waktu ke waktu. PC1_lag memiliki korelasi positif yang signifikan pada PDRB Nganjuk, sedangkan PC2_lag memiliki korelasi negatif yang lebih kecil. Korelasi PC3_lag lebih bervariasi dan lebih kecil dibandingkan PC1_lag dan PC2_lag. Model ini memiliki kemampuan prediksi yang tinggi dengan pseudo R-squared sebesar 0.9584.

1.7 Hasil Evaluasi Time Varying Factor Augmented Linear Regression

Tabel 2.15 menunjukkan persentase kesalahan proyeksi untuk setiap variabel (PDRB total, industri pengolahan, dan sektor pertanian) pada tahun 2011 hingga 2020. Dalam proyeksi PDRB total, persentase kesalahan proyeksi berkisar antara -5.186% hingga 4.946%. Model umumnya memiliki kinerja yang baik, dengan rata-rata persentase kesalahan proyeksi sebesar 0.944%. Persentase kesalahan proyeksi industri pengolahan berkisar antara -13.467% hingga 9.447%. Model menunjukkan kinerja yang lebih bervariasi dibandingkan dengan proyeksi PDRB total. Terdapat beberapa tahun dengan proyeksi yang kurang akurat, terutama pada tahun 2014 (-13.467%) dan 2019 (-10.285%). Persentase kesalahan proyeksi lapangan usaha pertanian, kehutanan, dan perikanan berkisar antara -6.984% hingga 5.655%. Model menunjukkan kinerja yang relatif stabil dibandingkan dengan proyeksi PDRB total dan industri pengolahan. Rata-rata persentase kesalahan proyeksi adalah 1.510%, menunjukkan proyeksi yang cukup akurat.

Secara keseluruhan, model menunjukkan kinerja yang cukup baik dalam memproyeksikan PDRB total, industri pengolahan, dan sektor pertanian di Nganjuk. Model ini mampu menangkap tren dan pola dalam data dengan cukup akurat.

Tabel 2.15. Hasil Evaluasi In-Sample Proyeksi Time Varying Factor Augmented Linear Regression.

Tahun	Percentage Error PDRB total (%)	Percentage Error Industri Pengolahan (%)	Percetage Error Pertanian, Kehutanan, dan Perikanan (%)
2011	0.219	3.580	3.616
2012	-0.798	4.100	-0.520
2013	1.511	1.418	-0.088
2014	-0.743	-10.285	5.655
2015	1.482	8.492	3.586
2016	4.946	9.447	-0.393

2017	-1.910	0.860	-3.104
2018	-5.186	0.816	-1.217
2019	-4.239	-13.467	0.037
2020	0.577	-2.442	-6.984

Sumber: Peneliti, diolah.

Tabel 2.16 menunjukkan persentase kesalahan proyeksi out-sample untuk setiap variabel (PDRB total, industri pengolahan, dan sektor pertanian kehutanan perikanan) pada tahun 2021 dan 2022. Persentase kesalahan proyeksi PDRB total untuk tahun 2021 dan 2022 adalah -41.925% dan -43.901%. Hasil ini menunjukkan bahwa model ini tidak akurat dalam memproyeksikan PDRB total pada periode out-sample. Hasil pada tabel juga menunjukkan bahwa model ini kurang akurat dalam memproyeksikan industri pengolahan pada periode out-sample. Selain itu, besarnya persentase kesalahan proyeksi (>40%) pada proyeksi pertanian, kehutanan, perikanan menunjukkan bahwa proyeksi model jauh dari nilai aktual, sama seperti PDRB total.

Tabel 2.16. Hasil Evaluasi Out-Sample Proyeksi Time Varying Factor Augmented Linear Regression.

Tahun	Percentage Error PDRB total (%)	Percentage Error Industri Pengolahan (%)	Persentase Error Pertanian, Kehutanan, dan Perikanan (%)
2021	-41.925	-10.060	-46.100
2022	-43.901	-17.517	-47.944

Sumber: Peneliti, diolah.

1.8 Perbandingan Performa Antar Model

Berdasarkan persentase kesalahan out-sample, Panel VAR menunjukkan kinerja yang lebih baik untuk semua variabel dan periode yang dibandingkan dari 2021 ke 2022. Performa proyeksi Panel VAR dan Bayesian Global VAR lebih baik dibandingkan performa proyeksi Time Varying Factor Augmented Linear Regression untuk PDRB total, industri pengolahan, dan pertanian. Alasan utama adalah Panel VAR dan Bayesian Global VAR menggunakan lebih banyak observasi dan mampu memasukkan hubungan antar kabupaten/kota di Jawa Timur.

Model Panel VAR dan Bayesian Global VAR menggunakan lebih banyak observasi dengan memasukkan data dari berbagai kabupaten/kota di Jawa Timur. Cakupan data yang

lebih luas ini memungkinkan model tersebut untuk menangkap pola dan hubungan yang lebih kompleks dalam perekonomian, sehingga menghasilkan proyeksi yang lebih akurat.

Tidak seperti Time Varying Factor Augmented Linear Regression yang berfokus pada masing-masing kabupaten/kota secara terpisah, Panel VAR dan Bayesian Global VAR secara eksplisit memodelkan saling ketergantungan dan interaksi antar wilayah tersebut. Kemampuan untuk memperhitungkan hubungan antar kabupaten/kota ini memberikan pemahaman yang lebih menyeluruh tentang dinamika ekonomi dan memungkinkan perkiraan yang lebih tepat. Dengan menggabungkan data dari berbagai wilayah, model ini dapat menangkap variasi regional, mengidentifikasi tren umum, dan memperhitungkan efek limpahan antar kabupaten/kota. Perspektif yang lebih luas ini menghasilkan proyeksi yang lebih kuat dan dapat digeneralisasikan.

Model Panel VAR dan Bayesian Global VAR secara eksplisit memasukkan saling ketergantungan dan interaksi antar kabupaten/kota ke dalam struktur model mereka. Hal ini memungkinkan mereka untuk menangkap bagaimana guncangan ekonomi atau perubahan kebijakan di satu wilayah dapat memengaruhi wilayah lain melalui perdagangan, migrasi, atau bentuk hubungan ekonomi lainnya. Dengan memperhitungkan hubungan antar kabupaten/kota ini, model tersebut dapat menghasilkan perkiraan yang lebih akurat yang mencerminkan sifat saling keterkaitan perekonomian di Jawa Timur.

Panel VAR memiliki kesalahan yang lebih kecil (absolut) dibandingkan BGVAR dan Time Varying Factor Augmented Linear Regression pada kedua tahun untuk PDRB total dan lapangan usaha pertanian, kehutanan, dan perikanan. Meskipun kedua model memiliki kesalahan di atas 10%, Panel VAR menunjukkan perbedaan yang sedikit lebih baik pada kedua tahun untuk lapangan usaha industri pengolahan.

Kinerja Panel VAR yang lebih baik daripada Bayesian Global VAR (BGVAR) kemungkinan besar disebabkan oleh masalah konvergensi dalam model BGVAR. Hal ini ditunjukkan oleh fakta bahwa 28.79% variabel dalam model BGVAR memiliki statistik Geweke yang berada di luar kisaran $\pm 1,96$.

Dalam konteks estimasi model menggunakan simulasi MCMC (Markov Chain Monte Carlo), konvergensi mengacu pada kemampuan simulasi mencapai keadaan stabil di mana distribusi perkiraan parameter model tidak lagi berubah secara signifikan dari iterasi ke iterasi. Dengan kata lain, estimasi parameter model menjadi stabil dan tidak lagi "berkeliraran".

Masalah konvergensi dapat berdampak buruk pada kinerja model. Jika estimasi parameter model tidak stabil, maka perkiraan yang dihasilkan oleh model tersebut mungkin tidak akurat dan dapat menghasilkan kesalahan perkiraan yang lebih besar. Beberapa alasan yang menyebabkan kondisi ini terjadi adalah simulasi MCMC tidak berjalan cukup lama dan model yang terlalu kompleks relatif terhadap kondisi ketersediaan data.